

---

## 第12章 昇腾实验助手的实现

### 12.1大语言模型实践基础及昇腾实践

#### 12.1.1实验助手项目背景与发展动态

在人工智能技术的不断进步和创新的驱动下，大型语言模型（LLM）与知识库的深度融合正逐步成为推动自然语言处理（NLP）以及整个人工智能领域技术发展的关键力量。LLM 的出现和发展改变了人们与机器之间的交互模式，也推动了机器在理解和生成语言方面的能力达到前所未有的高度。而知识库的引入为 LLM 提供了更为专业、深厚的信息支撑。两者的融合在多个领域，如智能问答、智能客服、智能医疗、智能机器人等方面发挥了巨大的应用价值。全球范围内，这一技术融合正在迅猛发展，展现出强劲的生命力与广泛的应用前景。

##### 1. 国内发展现状

国内在 LLM 与 RAG 结合的技术研发与应用领域取得了显著成就。国内的技术公司和高等院校在这一领域的合作日益密切，政府的政策支持和开放的技术生态系统也为这一技术的快速发展创造了有利条件。国内多个企业已经将 LLM 与 RAG 技术应用于智能问答助手、移动机器人等领域，通过深度融合大幅提升了交互效率与智能化水平。

###### 1)百度“文心一言”与外部知识库的深度融合

百度的“文心一言”模型，作为国内领先的大语言模型之一，通过与百度百科、百度搜索引擎等丰富数据源的深度融合，提升了其在自然语言理解（NLU）和生成（NLG）方面的能力。文心一言不仅能够理解用户的自然语言输入，还能根据用户需求在海量的知识库中快速检索信息，提供精准的答案。该模型特别在智能问答和信息检索领域表现突出。例如，用户向“文心一言”询问“量子计算的最新研究进展”时，系统能够结合百度百科中的相关条目、学术文献和相关新闻，从多个维度为用户提供详细的解答。这一技术使得“文心一言”在智能客服、教育、医疗等多个行业得到广泛应用。在教育领域，它被用来提供智能辅导服务，通过融合教材、学术论文、教学视频等资源，为学生提供定制化的学习内容；在医疗领域，“文心一言”结合医学知识库，提供疾病查询、诊断建议等功能，帮助医生和患者更高效地获取相关信息。

###### 2)阿里巴巴智能客服与 RAG 结合

阿里巴巴的智能客服系统利用 RAG 技术，极大提升了其在电商、金融和教育等领域的服务效率。在电商平台上，阿里巴巴通过将自然语言处理技术与商品数据库、用户行为分析和搜索引擎数据结合，实现

---

了个性化推荐和精准客服响应。例如，当用户询问某款手机的详细功能时，智能客服能够从产品知识库中获取产品参数、用户评价和技术规格，实时为用户推荐最匹配的商品。这一系统能够自动学习并优化与用户互动的策略，通过理解用户的情感和意图，提升服务质量和客户满意度。阿里巴巴还在金融领域运用这一技术为用户提供投资建议和风险评估，系统通过分析市场趋势数据和金融产品知识库，帮助客户做出更精准的投资决策。此外，在在线教育领域，阿里巴巴的智能客服结合课程资料和教材知识库，提供学科辅导和个性化学习计划，满足学生在学习过程中的不同需求。

### 3) 华为云 AI 与 LLM 结合的应用

华为云通过结合 LLM 与专业领域的知识库，推出了一系列智能化应用，服务于智能制造、医疗健康和智慧城市等多个领域。在智能制造领域，华为云推出的智能生产管理系统通过实时获取设备数据、分析生产环境并与设备维护知识库结合，实现了预测性维护和生产效率提升。例如，系统能够监测生产线设备的运行状态，通过分析历史数据和设备故障知识库，预测设备故障风险，并提前安排维修，从而降低停机时间和维修成本。在智能医疗领域，华为云结合医学知识库和电子病历系统，开发了智能医疗决策支持系统。该系统可以根据患者的历史病历、症状描述以及相关医学文献，推荐个性化的治疗方案，辅助医生在诊断和治疗中做出更为精准的决策。此外，华为云的智慧城市解决方案通过将城市管理数据、交通监控、环境监测等信息与 LLM 相结合，实现了智能化城市管理和优化。

## 2. 国际发展现状

在国际上，基于 LLM 与 RAG (Retrieval-Augmented Generation) 的融合也呈现出快速发展的趋势。OpenAI、Google、Meta 等公司在这一领域已经取得了显著成果。OpenAI 的 GPT 系列模型、Google 的 BERT、Meta 的 Llama 等都是这一领域的重要代表。这些模型不仅在自然语言生成与理解方面表现出色，还通过与外部检索系统和知识库的深度结合，从而提升了智能交互系统的性能，特别是在如移动机器人交互等专业应用场景中展现出巨大的潜力。

### 1) OpenAI 的 GPT 系列模型与 RAG 结合

OpenAI 的 GPT 系列（如 GPT-3 和 GPT-4）通过与 RAG 技术结合，显著提升了模型在多个领域的应用能力。通过集成领域特定的数据库、文献和 API 接口，GPT 可以实时获取和更新知识，以便生成准确且专业的答案。在移动机器人交互系统中，GPT 与外部知识库结合，通过检索获取特定领域的信息，进一步丰富了机器人的知识图谱，使其能够在动态环境中更智能地响应用户的需求。例如，GPT 可以实时查询机器人所在位置的环境信息，结合地图和导航数据，帮助机器人优化路径规划和决策。在智能机器人应用中，GPT 与 RAG 结合可实现更灵活的对话和任务执行。通过 RAG，机器人不仅能理解自然语言，还能通

---

过检索外部信息补充对话内容，为用户提供个性化的服务。例如，在工业环境中，机器人可以通过检索设备维护知识库提供相关操作指南，帮助工作人员进行设备维护。

## 2) 自动驾驶与 LLM 融合

自动驾驶技术的成功不仅依赖于传感器和计算机视觉技术，还需通过与 LLM 结合，进一步增强决策智能性。Waymo 与特斯拉等公司将 LLM 融入自动驾驶系统，通过分析实时交通数据、历史行车记录与外部知识库（如交通法规、地图数据）相结合，优化路径规划和驾驶决策。以 Waymo 为例，该系统利用激光雷达和摄像头获取周围环境的实时数据，同时结合 LLM 分析来自交通管理系统、路况监测系统和交通事故数据等信息，动态调整路径选择，避免交通拥堵或事故区域，确保驾驶安全并提升行车效率。特斯拉的自动驾驶系统也在实时路况分析中发挥了 LLM 的作用，通过深度学习和外部交通数据库相结合，优化驾驶路径和避险策略。

## 3) 医疗领域的 RAG 应用

在医疗领域，LLM 应用展现了巨大的潜力，尤其是在智能诊断和个性化医疗服务中。IBM Watson Health 是一个典型案例，它结合了医学领域的大规模知识库和 LLM，通过 RAG 技术为医生提供癌症、心脏病等复杂疾病的诊断和治疗支持。Watson 能够分析患者的病历、基因组数据以及全球医学研究成果，自动为医生推荐个性化的治疗方案。在移动机器人应用中，结合 RAG 技术的医疗机器人能够实时获取医学文献、病例数据库等信息，为医生提供更精准的决策支持。例如，机器人可以根据患者的历史病历、症状描述及医学文献中的最新研究成果，为患者提供最适合的治疗建议。这种结合不仅提升了医疗服务的准确性，还能减少因信息不对称造成的误诊风险。

## 4) 技术标准化与开放生态

随着 LLM 的广泛应用，技术的标准化和开放生态的建设变得愈发重要。开放生态不仅促进了技术的普及和创新，也推动了全球范围内的合作。OpenAI、Google、Meta 等公司开放了 GPT、BERT 和 LLaMA 等模型的训练代码和 API 接口，促使全球开发者能够在不同场景中使用这些技术，并根据自己的需求进行定制化开发。OpenAI 的 GPT-3 开放 API 接口，允许企业和开发者将其集成到智能客服、自动化写作、语言翻译等多个应用中，极大地加速了人工智能技术在商业和教育领域的应用。此外，国际标准化组织（如 IEEE、ISO）也在推动 AI 技术的标准化制定，确保数据隐私保护、安全性规范等方面的合规性。这种标准化不仅有助于各大企业在全全球市场的合规应用，也推动了不同国家和地区在 AI 技术研究与开发上的协作与共享。

# 3. 发展动态

---

随着大语言模型（LLM）与知识库深度融合技术的不断发展，这些技术在智能化、多模态化、跨领域融合等多个方向展现出广阔的发展空间。特别是在智能问答助手领域，LLM 与知识库的融合已经带来更高效、精准和用户友好的交互体验，推动各行业的智能化升级。当前的智能问答助手正在不断提升交互水平，系统具备自学习、自适应和自优化的能力。将 LLM 与知识库深度融合，不仅能够提高自然语言理解与生成的准确性，还可以增强对上下文信息的处理与推理能力。智能助手可以更好地理解用户需求、意图与情境，从而提供更高效、个性化的服务。

在实际应用中，智能问答助手已经在企业、教育、医疗等领域发挥重要作用。例如，在企业客服领域，智能问答助手可以接入企业内部的知识库，通过 LLM 理解客户的问题并迅速检索相关信息，从而提供高效准确的解答。与传统客服相比，这不仅可以减少人工客服的压力，还可以提升服务效率与用户满意度。在教育领域，智能问答助手能够根据学生的学习状态、兴趣偏好以及课程进度提供个性化学习资源。例如，系统可以从知识库中检索特定学科资料，通过 LLM 生成易于理解的学习内容，同时根据学生的提问与反馈调整推荐内容。这不仅提升了学生的学习体验，还帮助教师更好地了解学生的学习情况，从而提供更有针对性的教学指导。在医疗领域，智能问答助手与医学知识库相结合，可以提供专业的健康咨询与诊断建议。通过 LLM 对症状描述进行理解，再从知识库中检索临床指南与病例数据，系统可以提供更精准的初步诊断建议。例如，患者在描述自己的症状后，智能助手可以推荐可能的疾病、建议进一步检查，并连接远程医疗专家进行更专业的指导，从而提高医疗效率与诊断准确性。

当前的智能问答助手不仅限于文本与语音交互，还开始整合视觉、手势、触觉等多模态感知技术，以提供更自然、直观的交互体验。将 LLM 与视觉、听觉、手势等感知技术相结合，系统能够更好地识别用户意图与需求，从而提供更加人性化的交互体验。

#### 1) 智能问答系统的多模态交互

智能问答系统不再局限于传统的文本输入或语音识别。在视觉、语音、手势、触觉等多种感知方式的加持下，系统的理解能力得到了大幅提升，能够更好地识别用户的需求和情绪，进而做出更加精准的响应。以微软的 Cortana、亚马逊的 Alexa 为例，它们不仅支持语音指令，还逐渐引入了面部表情识别、眼动追踪等功能。例如，Amazon Echo Show 系列设备在配备屏幕的基础上，加入了视频通话和面部表情识别功能，使得系统能通过用户的表情和语音来判断其情绪变化。如果用户语音指令中带有焦虑或疑问的语气，系统会适时地调整语气或提供更多相关信息。

视觉交互的一个典型案例是苹果的 Face ID 技术。Face ID 不仅能通过视觉识别技术解锁设备，还能根据用户的面部表情进行系统调节。例如，若用户的面部表情显示出焦虑，设备可能会调节其界面内容以提

---

供舒缓体验。此外，语音与视觉结合的技术也在不断发展。Google 的 Nest Hub Max 设备不仅能通过语音识别处理日常指令，还能通过内置摄像头分析用户的情绪变化，调整其对话内容，使交流更加自然。

## 2) 多模态交互在智能家居领域的应用

智能机器人，尤其是在服务行业中的应用，借助多模态交互技术，能够大大提升用户体验。在医院、商场、机场等公共场所，服务机器人通过视觉、语音、触觉等多种感知方式提供服务。一个典型的案例是日本的 Pepper 机器人，它能够识别用户的面部表情、语音并作出相应的反应。在医院中，Pepper 能够通过面部表情识别技术判断患者的情绪状态，并提供温馨的互动，帮助患者缓解焦虑情绪。通过语音与触摸屏结合，Pepper 可以回答患者的问题、提供病房导航等服务。

在医疗场景中，医疗机器人如 Intuition Robotics 的“ElliQ”智能机器人则通过结合视觉与语音，不仅能与老年人进行对话，还能分析其表情和身体语言，提供更加贴心的陪伴和护理服务。例如，当机器人检测到用户面部表情显示出困扰或焦虑时，系统可以主动询问是否需要帮助，甚至推荐健康管理建议。这种结合多模态输入的技术使得机器人能够更好地适应用户的情感和需求，提供更为人性化的服务。

## 3) 多模态交互在智能机器人领域的应用

智能机器人，尤其是在服务行业中的应用，借助多模态交互技术，能够大大提升用户体验。在医院、商场、机场等公共场所，服务机器人通过视觉、语音、触觉等多种感知方式提供服务。一个典型的案例是日本的 Pepper 机器人，它能够识别用户的面部表情、语音并作出相应的反应。在医院中，Pepper 能够通过面部表情识别技术判断患者的情绪状态，并提供温馨的互动，帮助患者缓解焦虑情绪。通过语音与触摸屏结合，Pepper 可以回答患者的问题、提供病房导航等服务。

在医疗场景中，医疗机器人如 Intuition Robotics 的“ElliQ”智能机器人则通过结合视觉与语音，不仅能与老年人进行对话，还能分析其表情和身体语言，提供更加贴心的陪伴和护理服务。例如，当机器人检测到用户面部表情显示出困扰或焦虑时，系统可以主动询问是否需要帮助，甚至推荐健康管理建议。这种结合多模态输入的技术使得机器人能够更好地适应用户的情感和需求，提供更为人性化的服务。

## 4) Agent 技术与多模态交互的结合

Agent 技术与多模态交互的结合，能够使得系统更加智能，提供主动的推理和决策能力。智能 Agent 不再仅仅是执行用户指令的工具，它能够实时分析多种感知输入，并作出智能决策。在智能家居中，Agent 技术能够根据用户的语音、手势、表情等输入，动态地调整设备的状态。例如，用户进入房间后，Agent 能够根据用户的面部表情和语音指令调整灯光、温度和音乐等，以提供最佳的环境体验。

在医疗领域，Agent 技术结合多模态交互也表现出了巨大的潜力。例如，IBM Watson Health 平台就通过 Agent 技术结合多模态输入，为医生和患者提供个性化的医疗建议。患者通过语音与系统交流时，Agent

---

会结合患者的表情、语音情绪等信息，判断其健康状况，并为其提供相应的建议。此外，Agent 还能整合医院的医学知识库，在帮助患者定位科室、预约就诊的同时，提供详细的医学咨询服务。

## 12.1.2 大语言模型概述

大语言模型（Large Language Models, LLMs）是一类基于深度学习框架构建的自然语言处理（NLP）模型，它能够对语言进行深入的理解和生成。通过大规模的文本数据训练，这些模型能够学习语言的语法结构、语义关系以及上下文依赖，从而具备生成连贯文本、回答问题、文本分类等多种任务的能力。

近年来，随着技术的发展，多模态大语言模型（Multimodal LLMs）应运而生，它将文本、图像、音频等多种不同模态的数据整合到同一个模型中，扩展了大语言模型的应用范围和能力，使其不仅能够处理文本信息，还能够同时理解并生成其他形式的输入，如图像、视频和音频等。多模态大语言模型的核心优势在于它能够同时处理多种类型的数据，并进行综合推理。例如，在医疗影像分析中，多模态模型可以结合医学影像数据与患者的电子病历，进行更加精准的诊断。又如，在智能机器人系统中，模型可以同时分析视频流、语音指令和环境数据，从而执行更为复杂的任务。通过这种方式，模型不仅能够理解单一模态的数据，还能够跨模态进行深度推理，从而提升任务的执行能力和系统的智能化水平。

大语言模型的工作流程一般可以分为两个阶段：预训练和微调。在预训练阶段，模型通过大规模文本数据进行自监督训练，通常采用词预测或遮蔽语言建模（Masked Language Modeling, MLM）等任务，使得模型能够捕捉到语言的通用规律和上下文关系。通过这一阶段，模型不仅能够学习到词汇间的关联，还能建立起较为复杂的语言模型。紧接着，在微调阶段，模型会针对特定任务进行监督学习，优化其在特定应用场景下的性能，例如在问答系统中，通过微调提升模型理解问题和生成答案的能力。

大语言模型的独特优势在于其在处理自然语言任务时的高度灵活性和泛化能力，其主要技术特点包括以下几个方面：

1) 大规模语料库：大语言模型的训练通常依赖于海量的文本数据集，这些数据集包含了丰富的语言知识，覆盖了广泛的主题和领域。通过对这些数据的训练，模型能够捕捉到语言中的细微特征，并有效地学习到上下文信息。

2) 文本生成能力：大语言模型具备生成连贯、自然语言文本的能力，这使得其在文本生成、摘要撰写、机器翻译等领域表现出色。模型能够根据输入的提示生成合理的后续内容，甚至可以在特定上下文下创作符合情境要求的文本。迁移学习：由于预训练阶段学习了大量通用的语言特征，这些模型可以通过微调适应各种特定任务，而无需从头开始训练。

---

3) 上下文感知能力：与传统的语言模型相比，大语言模型能够基于先前的上下文信息进行推理，预测后续的词语或句子。它通过深层的网络结构，能够捕捉和保留长距离的上下文依赖，尤其在长篇文本和复杂对话中表现尤为突出。

4) 迁移学习能力：大语言模型通过预训练阶段积累的知识，在完成基础训练后可以通过微调适应不同的任务需求。这种迁移学习的能力使得大语言模型能够在多个任务中表现良好，避免了从头开始训练的高成本，并能够迅速转化为实际应用。

5) 表示学习能力：大语言模型能够通过预训练过程学习到语言的分布式表示，这使得它在理解语义和推理问题上具有较强的能力。模型不仅能理解语言的表面结构，还能进行深层次的语义推理和关联分析，帮助完成复杂的语言理解任务。

大语言模型（LLMs）的核心构成通常包括多个神经网络层次，这些层次通过不同的深度学习架构实现。在本项目中，采用 PyTorch 框架构建和训练模型，避免使用传统的 Transformer 架构，而是聚焦于其他高效的神经网络架构，特别是循环神经网络（RNN）、长短期记忆网络（LSTM）和门控循环单元（GRU）。这些架构能够有效捕捉长距离依赖关系，尤其在处理多轮对话和上下文信息时，能够保持更好的语义一致性。

在 PyTorch 框架中，我们可以采用长短期记忆网络（LSTM）或门控循环单元（GRU）等递归神经网络（RNN）结构来处理序列数据。RNN 本身具有处理序列的能力，通过递归地将前一个时间步的输出作为当前时间步的输入，来逐步构建序列的上下文信息。然而，标准的 RNN 在长距离依赖的捕捉上存在一定困难，这也是 LSTM 和 GRU 被提出的原因，它们通过引入门控机制，有效缓解了梯度消失和梯度爆炸问题，从而能够捕捉更长时间序列中的信息。此外，PyTorch 中的卷积神经网络（CNN）也能够处理序列数据，尤其是在文本分类和特征提取的任务中，CNN 可以通过多个卷积层和池化层来提取局部特征，并通过全连接层输出最终的预测结果。虽然 CNN 主要用于提取局部模式，但它在在大语言模型中仍然可以用于构建语言表示，并且能够显著加速训练过程。

### 12.1.3 昇腾模型部署：模型选择与边缘端裁剪量化

在当前的自然语言处理领域，GPT（Generative Pre-trained Transformer）系列模型目前是最具影响力和广泛应用的代表之一，包括 GPT-3.0、GPT-4.0 和 GPT-4o mini 等版本。但随着大语言模型（LLM）技术的进步，除了 GPT 系列外，越来越多的开源大语言模型相继问世，具有代表性的开源大模型主要有以下几类：

---

### 1) LLaMA (Large Language Model Meta AI)

LLaMA 是由 Meta (前 Facebook) 推出的一个开源大语言模型系列, 旨在提供高效且灵活的替代方案, 挑战传统的 GPT 系列模型。LLaMA 家族包含多个版本, 涵盖从小型的 LLaMA-7B 到大型的 LLaMA-65B, 适应不同的计算资源和任务需求。LLaMA 的设计强调计算效率与多样化的模型规模, 特别适合低资源设备和边缘计算场景。其权重和代码完全开源, 促进了学术研究和社区参与。LLaMA 在文本生成、问答系统、情感分析等多个自然语言处理任务中都有广泛应用, 并且由于其灵活性, 特别适合定制化开发。

### 2) BLOOM (BigScience Large Open-science Open-access Multilingual Language Model)

BLOOM 是由 BigScience 项目开发的开源多语言大语言模型, 致力于支持多语言处理。它能够理解和生成多种语言的文本, 广泛适用于跨语言任务, 如多语言问答、机器翻译和跨语言搜索等。BLOOM 采用开源发布, 所有模型权重和代码均可免费下载, 促进了全球研究社区的贡献和模型优化。其强大的多语言能力使其成为国际化应用的理想选择, 特别适合需要处理跨语言信息的场景。BLOOM 的生成能力还使其在文本生成、摘要生成和文档处理等领域表现突出。

### 3) T5 (Text-to-Text Transfer Transformer)

T5 是由 Google Research 提出的一个开源语言模型, 核心理念是将所有自然语言处理任务转化为“文本到文本”的问题。这种统一的任务处理框架使得 T5 在多种任务中都能够表现优异, 无论是文本生成、机器翻译还是情感分析、摘要生成等。T5 通过多任务学习进行训练, 能够共享不同任务之间的知识, 提高训练效率。模型的可扩展性很强, 开发者可以通过微调来适应特定领域或任务的需求, 广泛适用于多种实际应用场景。T5 的开源性和高效性使其成为一个重要的工具, 尤其在需要处理各种任务的情况下, 提供了高度灵活的解决方案。

这些模型通过在海量的互联网文本数据上进行自监督学习, 在预训练阶段掌握了语言的深刻理解, 能够捕捉语言的语法结构、句法关系和上下文信息, 从而具备生成连贯文本、回答问题、文本分类等多种任务的能力。

## 12.1.4 基于 RAG 的知识库构建

RAG (检索增强生成) 技术是一种结合信息检索与生成模型的创新方法, 旨在弥补传统检索模型在语义理解和复杂查询处理上的局限性。传统的检索技术主要依赖于关键词匹配, 存在查准率低、查全率差以及对复杂查询支持不足等显著问题。这种方法在处理需要语义理解的查询时, 往往无法有效捕捉查询与文档之间的深层次关联, 导致无法充分挖掘潜在的信息。而 RAG 技术通过引入检索模块, 从大规模知识库中检索与输入内容相关的文档或信息, 并将检索到的内容与输入共同作为生成模型的输入, 进一步指导模




型生成更加准确、丰富和语境相关的答案。此过程不仅提升了生成输出的语义相关性，还显著改善了查询的查全率与查准率，尤其在处理涉及同义词、专业术语或不常见表述的情况下表现尤为突出。

RAG 的核心优势在于其灵活集成了检索与生成两个模块，使得模型能够在生成过程中动态引用外部知识库，从而在无需重新训练的情况下，大幅提升对特定领域或组织内知识的利用效率。例如，在面对科技奖励、医学诊断、法律咨询等专业领域的应用时，RAG 能够通过高效的文献检索与即时的知识整合，生成基于当前领域知识的精准回答。这一优势使得 RAG 不仅能够处理传统信息检索所难以应对的复杂查询，还能够实现语义推理，提供涉及多因素推断和知识迁移的输出。

基于 RAG 的知识库构建是一个多步骤的过程，通常包括数据收集、文档索引、向量化处理、检索模块的设计以及生成模块的训练与集成。

基于 RAG 的问答系统结构流程图



基于 RAG 的问答系统架构

### 1) 数据来源与采集方式

构建一个高效的 RAG 系统的第一步是准备知识文档。现实中的知识源可能包括多种格式的文件，如文本文件、PDF 文件、Word 文档、Excel 表格，甚至图片和视频等。在实际应用中，知识库需要通过适当的工具将这些不同格式的数据转换为结构化的文本数据。

---

## 2) 文本切分

一旦完成了数据的采集和预处理，下一步便是进行文本切分。文本切分的目的是将长文档分割成多个较小的文本块，这样可以确保每个文本块适合嵌入模型的输入限制，并且更有利于检索时找到最相关的部分。对于嵌入模型，输入的文本长度是有限制的，通常大约为 512 个 Token（词元）。如果文档过长，超过了模型的限制，就必须将其切分成多个部分。

文本切分不仅仅是为了满足输入长度的要求，更关键的是确保每个分块的信息尽量紧凑且相关，避免过多的噪声。如果一个文本块太大，可能会包含过多无关的信息，导致检索结果的准确性降低；而如果文本块太小，又可能导致丢失必要的上下文信息，影响生成模块对用户查询的回答质量。因此，在切分时要根据最大 Token 长度（如 512）和最小 Token 长度进行平衡。通常，可以使用句子分割、段落分割等方法，结合滑动窗口技术确保文本块的语义完整性和连贯性。

## 3) 数据向量化

知识库的核心是向量化后的文本块。传统的知识库使用原始文本进行检索，但在基于 RAG 的系统中，文本块被转换为高维向量，存储于知识库中。每个文本块在向量空间中有一个对应的向量表示，通常使用深度学习模型（如 BERT、RoBERTa 等）来实现这一向量化过程。这些模型能够基于上下文语境生成语义丰富的向量表示，并通过计算向量间的相似性来完成检索任务。

向量化的过程本质上是将每个文本块映射到一个多维空间，文本的语义信息被保存在向量中。目标是确保每个文本块的向量表示能够有效地捕捉到其核心语义信息。随着向量化技术的发展，越来越多的专业工具和平台（如 sentence-transformers、FAISS 等）提供了便捷的接口，可以帮助开发者将文本转化为高维向量，以便后续的向量检索和生成任务。

## 4) 索引构建

向量化后的文本块存储在知识库中，但在实际应用中，我们需要高效的检索机制来快速匹配用户的查询与知识库中的文本块。如果没有索引支持，查询过程将是非常低效的，特别是在大规模数据集的情况下，逐一遍历所有向量来进行匹配将是不可行的。因此，构建索引是提升检索效率的关键。

目前，常用的向量检索库包括 Faiss 和 Milvus。常用的向量检索库 Faiss 和 Milvus 支持大规模数据的快速检索，其中 Faiss 由 Facebook 开发，支持包括倒排索引和 HNSW 在内的多种索引结构；而 Milvus 则提供多种索引策略。索引构建过程涉及将向量存入数据库并使用 KNN 等算法检索相似向量，同时需根据数据规模优化索引结构，如在大数据集上使用基于 HNSW 的结构以提升搜索效率和准确度。

通过构建高效的向量索引，RAG 系统能够在查询时快速找到与用户问题最相关的文档块，进而为生成模块提供更准确的上下文信息，保证生成结果的质量。

---

## 12.2实验机器人底盘及控制

### 12.2.1ROS 系统架构

### 12.2.2分布式节点通信（此处先不写，参考其他同学的章节后再看看怎么来写）

### 12.2.3硬件集成：香橙派 Aipro 与 Jetson Orin NX 双机通信

Orange Pi Aipro 与 NVIDIA Jetson Orin NX 的双机通信系统基于 TCP Socket 实现，采用 C/S（客户端/服务器）架构设计。服务端运行在 Orange Pi Aipro 上，负责监听连接请求并协调多路数据传输；客户端部署在 Jetson Orin NX 上，集成 ROS 机器人操作系统，实现智能机器人的实时控制。

在物理层连接上，两者通过千兆以太网直连，采用静态 IP 配置（192.168.8.193/24）避免 DHCP 波动带来的连接中断。经实测，该连接方案网络延迟稳定在 1.2ms 以内，完全满足机器人实时控制的高可靠性要求。

通信协议采用分层设计。文本指令以 JSON 格式传输，包含消息类型、时间戳及内容；图像数据通过自定义二进制协议传输，先发送 4 字节长度头，再传输 JPEG 压缩流。系统实现双缓冲队列管理，文本队列采用优先级调度，图像队列通过 mmap 零拷贝技术减少内存开销。Orange Pi Aipro 与 NVIDIA Jetson Orin NX 的通信技术方案采用分层式 Socket 架构设计，通过 TCP 协议实现稳定可靠的双向数据传输。在物理层连接上，两者通过千兆以太网直连，采用静态 IP 配置（192.168.0.146/24）避免 DHCP 波动带来的连接中断，实测网络延迟稳定在 1.2ms 以内。通信协议设计采用混合消息格式，文本指令使用 UTF-8 编码的 JSON 结构，包含消息类型、时间戳和内容体三个必填字段，而图像传输则采用自定义二进制协议——先发送 4 字节的大端序数据长度标识，再传输 JPEG 压缩后的图像数据流。

在软件实现层面，Orange Pi 作为服务端运行基于 Python 的 Socket 监听程序，采用非阻塞 I/O 多路复用机制处理并发请求。关键创新点在于设计了双缓冲队列：文本消息队列采用优先级调度（紧急指令如"终止跟随"优先处理），图像传输队列则实现零拷贝技术，通过内存映射文件直接操作摄像头采集的 YUV 数据。Jetson Orin NX 作为客户端，集成 ROS 通信框架与 Socket 模块的桥接层，当接收到"跟随我运动"等控制指令时，通过 ROS 的 Publisher 将消息转发至/yolo\_follow 话题，触发 DeepSORT 算法的多目标跟踪流程。

---

异常处理方面建立三级恢复策略：网络层通过心跳包检测连接状态（每 500ms 一次），超时 3 次后触发自动重连；应用层设置看门狗定时器监控进程状态，当 YOLOv5 进程崩溃时能在 800ms 内完成重启；业务层实现指令幂等性设计，避免重复指令导致的机器人动作异常。

服务端核心代码实现：

```
import socket
import time
import cv2
import numpy as np

# 创建 socket 服务端
sk = socket.socket()
sk.bind(("192.168.8.193", 8997))
sk.listen(10)
print("等待客户端连接...")

# 非阻塞 I/O 多路复用处理连接
conn, addr = sk.accept()
print(f'客户端已连接: {addr}')

def save_image(conn, filename):
    """图像接收与处理函数"""
    try:
        # 先接收 4 字节的长度信息（大端序）
        length_bytes = conn.recv(4)
        length = int.from_bytes(length_bytes, byteorder='big')

        # 分块接收图像数据，避免内存溢出
        img_data = b"
```

---

```

while len(img_data) < length:

    packet = conn.recv(min(4096, length - len(img_data)))

    img_data += packet

    # 零拷贝技术转换图像数据

    img_array = np.frombuffer(img_data, dtype=np.uint8)

    img = cv2.imdecode(img_array, cv2.IMREAD_COLOR)

    return img is not None

except Exception as e:

    print(f'图像处理错误: {e}')

    return False

```

Jetson Orin NX 作为客户端，集成 ROS 通信框架与 Socket 模块的桥接层。当接收到控制指令时，通过 ROS 的 Publisher 将消息转发至相应话题，触发相应的算法流程。

该通信方案已在本项目中实际部署，支持每秒 15 次的文本指令交互或 5fps 的实时视频传输。

```

#!/usr/bin/env python

import rospy

from std_msgs.msg import String

import socket

import cv2

import numpy as np

from sensor_msgs.msg import Image

import cv_bridge

from threading import Lock

class RobotCommunicationNode:

    def __init__(self):

        # ROS 节点初始化

        rospy.init_node('robot_communication', anonymous=True)

```

---

```
# 图像处理器初始化

self.bridge = cv_bridge.CvBridge()

self.image_lock = Lock()

self.latest_image = None


# Socket 连接建立

self.sk = socket.socket()

self.sk.connect(("192.168.8.193", 8997))


# ROS 发布者初始化

self.status_pub = rospy.Publisher('/robot_status', String, queue_size=10)

self.control_pub = rospy.Publisher('/control_commands', String, queue_size=10)


def image_callback(self, msg):

    """摄像头图像回调函数"""

    try:

        cv_image = self.bridge.imgmsg_to_cv2(msg, "bgr8")

        with self.image_lock:

            self.latest_image = cv_image

    except Exception as e:

        rospy.logerr("图像转换错误: %s", e)


def send_emotion_data(self, emotion_data):

    """发送情绪数据到服务端"""

    try:

        message = f"EMOTION:{emotion_data}"

        self.sk.sendall(bytes(message, encoding="utf8"))

        rospy.loginfo(f"情绪状态已发送: {emotion_data}")
```

except Exception as e:

```
rospy.logerr(f'情绪数据发送失败: {e}')
```

## 12.2.4 目标跟随：DeepSORT+YOLOv5 动态追踪

本项目中机器底盘的作用在于与人进行交互时自动化和智能化的技术来实现自主服务和问答，目标跟随的实现能够提高服务的准确性和效率、增强人机交互的体验、实现自动化和智能化的服务。在这一部分小车有 DeepSORT 算法能够实现对于单一目标的追踪。在本项目中，智能移动机器人学习助手的机器底盘融合了目标跟踪技术，其中 DeepSORT 算法的应用显著提升了目标追踪的精度和鲁棒性。通过 YOLOv5 进行的图像识别为 DeepSORT 提供了精确的目标候选区域，这使得机器人能够快速锁定并持续追踪图像中的人物。PID 控制器的引入，以其对系统误差的即时响应和累积误差的消除，确保了机器人跟随动作的稳定性和平滑性，避免了过冲和震荡现象，提高了跟随的效率。

### PID 控制流程图




图 PID 控制流程图

---

系统在首次识别时为人物分配的 ID 在整个跟踪过程中保持一致，增强了对特定目标的持续关注能力。整个系统的设计充分考虑了实时性和适应性，能够适应快速变化的环境和不同的工作条件，同时在设计中融入了安全性的考量，确保了交互过程的安全性。通过这些技术的整合应用，机器人学习助手不仅在功能上得到了增强，而且在用户体验上也实现了质的飞跃。

## 12.2.5情绪识别：DeepFace+ROS 多线程流水线

基于 DeepFace 的情绪识别模块以 ROS 框架为基础架构，通过高效的图像处理流水线和多线程机制，确保在嵌入式设备上也能实现稳定的情绪检测性能。系统从摄像头获取视频流后，首先对图像进行预处理，包括格式转换和分辨率调整，将原始图像缩小到 192x144 像素以提高处理效率，同时保留足够的面部特征信息供情绪分析使用。

在核心的情绪识别环节，系统采用了 DeepFace 深度学习框架进行分析，该框架集成了多种先进的卷积神经网络模型，能够识别 7 种基本情绪状态。为了提高识别准确率，系统设置了人脸检测置信度阈值，只有当检测到的人脸置信度超过该阈值时才会进行情绪分类。识别结果通过 ROS 话题实时发布，同时写入本地文件，为其他模块提供情绪数据接口。系统还设计了完善的异常处理机制，当无法检测到有效人脸或识别过程出现错误时，会自动发布默认状态并记录日志，保证系统的鲁棒性。

```
# DeepFace 情绪分析核心调用
```

```
results = DeepFace.analyze(  
    frame,  
    actions=['emotion'],  
    enforce_detection=False,  
    silent=True  
)
```

三维人脸对齐技术是 DeepFace 的重要创新，通过对输入人脸图像进行精确的立体校正，有效克服面部姿态变化带来的识别挑战。该技术首先检测面部关键点，然后通过仿射变换将人脸对齐到标准姿态，为后续情绪分类提供归一化的输入数据。



---

在系统架构设计上，该模块采用了生产-消费者模式的多线程结构。主线程负责图像采集和情绪分析，独立的显示线程则负责可视化输出，两者通过线程锁机制安全地共享图像数据。为了平衡处理性能和资源占用，系统采用多线程架构确保实时性能，避免过度消耗计算资源。情绪识别结果不仅实时显示在带有人脸框和情绪标签的画面，还通过 ROS 的 Publisher 机制广播给其他订阅节点，实现与导航、语音交互等模块的深度集成，为构建情感智能的机器人系统提供了关键技术支撑。

```
class EmotionDetector:

    def __init__(self):

        # ROS 节点初始化

        rospy.init_node("emotion_detector")

        # 图像订阅设置

        self.image_sub = rospy.Subscriber(topic, Image, self.image_callback,

                                           queue_size=1, buff_size=2**24)

        # 情绪发布者

        self.emotion_pub = rospy.Publisher('emotion', String, queue_size=10)

        # 线程安全机制

        self.image_lock = Lock()

        self.emotion_lock = Lock()

        # 启动显示线程

        self.display_thread = Thread(target=self.display_loop)

        self.display_thread.daemon = True

        self.display_thread.start()
```

图像回调函数的优化设计：

```
def image_callback(self, msg):

    # 处理间隔控制，避免过度消耗资源
```

---

```
current_time = rospy.Time.now()

if (current_time - self.last_process_time) < self.process_interval:

    return

self.last_process_time = current_time


# 图像预处理：格式转换和分辨率调整

frame = self.bridge.imgmsg_to_cv2(msg, desired_encoding='bgr8')

frame = cv2.resize(frame, (192, 144)) # 降低分辨率提高处理速度
```

DeepFace 作为 Facebook 开发的面部识别和情绪分析技术，采用了一套基于深度学习的端到端解决方案。该技术方案的核心在于构建了一个多层的卷积神经网络架构，通过在大规模人脸数据集上的训练，使模型能够自动学习从面部图像中提取情绪特征的能力。DeepFace 的创新之处在于采用了三维人脸对齐预处理技术，将输入的人脸图像进行精确的立体校正，有效解决了面部姿态变化带来的识别难题，这一步骤显著提升了后续情绪分类的准确性。

在模型架构方面，DeepFace 使用了深度卷积神经网络结构，网络包含多个卷积层、池化层和全连接层，能够从原始像素数据中逐层提取从低层次到高层次的面部特征。网络末端采用 softmax 分类器输出情绪概率分布，支持识别愤怒、厌恶、恐惧、快乐、悲伤、惊讶和中性等七种基本情绪状态。为了提高模型的泛化能力，训练过程中采用了大规模的数据增强技术，包括随机旋转、缩放和光照变化等，使模型对各种拍摄条件下的面部图像都具有良好的适应性。



基于 DeepFace 的情绪识别系统流程图

基于 ROS 框架的 DeepFace 情绪识别模块采用多线程架构和高效图像处理流水线，通过摄像头获取视频流并进行预处理后，利用 DeepFace 深度学习框架实现 7 种基本情绪的实时检测，系统设置人脸置信度阈值确保识别准确性，并通过 ROS 话题发布和本地文件存储两种方式输出情绪数据，同时采用生产者-消费者模式分离图像采集分析和可视化显示功能，设置 1 秒处理间隔平衡性能与资源消耗，配合完善的异常处理机制和线程锁同步，最终实现稳定可靠的情绪识别功能，为情感智能机器人系统提供核心技术支持。

人脸检测与情绪分析：

try:

```

results = DeepFace.analyze(frame, actions=['emotion'],
                             enforce_detection=False, silent=True)

```

```

emotion_detected = False

```

```

if results and isinstance(results, list):

```

---

for face in results:

if 'region' in face and 'dominant\_emotion' in face:

# 提取人脸区域和情绪信息

x, y, w, h = face['region']['x'], face['region']['y'], \

face['region']['w'], face['region']['h']

emotion = face['dominant\_emotion']

# 置信度过滤，提高识别可靠性

if face.get('face\_confidence', 0) > 0.5:

with self.emotion\_lock:

self.current\_emotion = emotion

# 发布情绪结果

self.emotion\_pub.publish(emotion)

emotion\_detected = True

# 可视化标注

cv2.rectangle(frame, (x, y), (x + w, y + h), (0, 255, 0), 2)

cv2.putText(frame, emotion, (x, y - 10),

cv2.FONT\_HERSHEY\_SIMPLEX, 0.6, (0, 255, 0), 2)

系统设置了严格的置信度阈值（0.5），只有当检测到的人脸置信度超过该阈值时，才会进行情绪分类，这一机制有效减少了误识别的情况。

系统提供多种数据输出方式，支持与其他 ROS 节点的集成和实时监控。可视化界面不仅显示实时情绪识别结果，还通过人脸框和情绪标签提供直观的反馈，便于系统调试和效果评估。

# ROS 话题发布

self.emotion\_pub.publish(emotion)

---

```
# 本地文件存储

with open(self.emotion_file, 'w') as f:

    f.write(emotion)

# 实时可视化显示

def display_loop(self):

    cv2.namedWindow("Emotion Detection", cv2.WINDOW_NORMAL)

    while not rospy.is_shutdown():

        with self.image_lock:

            if self.latest_processed is not None:

                display_img = self.latest_processed.copy()

            if display_img is not None:

                cv2.imshow("Emotion Detection", display_img)

            if cv2.waitKey(1) & 0xFF == ord('q'):

                rospy.signal_shutdown("User requested shutdown")
```

## 12.3 实验机器软件功能框架

### 12.3.1 多模态交互协议：工具调用与任务调度

MCP 作为项目的底层协调框架，承担了多模型、多工具协同调用与数据传输管理的核心职能。系统基于客户端-服务器架构设计，采用标准化通信协议，确保各类模型、工具和服务能够在统一的调度机制下无缝对接。当前版本中，MCP 选用进程间异步通信（stdio）作为数据交换通道，通过异步 IO 机制确保多任务并发时的响应实时性与数据传输的高效性。这种设计有效规避了传统阻塞式调用导致的延迟问题，尤其适合部署在本地或资源受限环境中。与此同时，系统预留了通信协议扩展接口，后续可以灵活替换为 HTTP、WebSocket 或 gRPC 等更高效的远程通信协议，满足跨平台、多终端部署需求。




图 9 基于 MCP 将 LLM 与外部资源集成的架构图

MCP 的核心在于其智能化任务分配机制。系统通过自然语言解析和任务意图识别，依据用户输入内容自动判定所需调用的工具类型，并将请求分发给对应的模型或功能模块。该机制依托于 RolePlay 智能体框架，结合大语言模型 qwen-max 进行指令解析与角色扮演式调用管理。通过设置角色模板（Role Template）和功能列表（function\_list）限定每个智能体的功能权限，确保调用过程安全、可控。任务执行过程中，MCP 统一采用异步协程方式调度各工具执行，避免任务阻塞，提升系统整体吞吐效率。

系统在数据交换与功能集成方面，采用模块化工具注册机制，所有可调用工具通过 @mcp.tool() 装饰器进行注册，纳入统一调用体系。现阶段已集成天气查询、图像生成、网页浏览、新闻爬取、RAG 知识检索等功能，且具备良好的扩展性。第三方开发者只需按照约定格式编写函数，即可将新工具快速接入系

---

统，无需改动核心调度逻辑。这种设计极大增强了系统的灵活性与可扩展性，为后续构建多任务、多模态交互系统提供了稳定底座。

在知识问答与内容生成部分，MCP 结合了基于 RAG 技术的检索式智能问答方案，融合 MemoryWithRag 框架实现本地知识库检索与 LLM 问答协同。该方案通过对结构化文本与 PDF 文档向量化检索，实时召回相关知识片段，并交由大语言模型生成自然语言回答，兼顾信息准确性与语言流畅性。同时，为保障多源数据调用的灵活性，MCP 支持配置化知识库挂载及动态更新，适配动态知识场景。

算法层面，当前 MCP 在计算表达式时仍使用 eval 方式，存在安全隐患。未来可替换为 asteval 或 sympy 等安全沙箱计算库，避免恶意代码执行风险。在多任务调度机制方面，目前调度优先级基于工具注册顺序与请求顺序，未来可引入基于任务权重、资源占用、响应时间等维度的优先级动态调整机制，提升复杂环境下的资源调度效率。此外，为提升高并发环境下的数据一致性与消息顺序保障，考虑在异步 IO 通信基础上叠加任务队列与消息缓冲池机制，降低突发高流量场景下的服务压力。

### 12.3.2 基于 Modelscope Agent 的框架搭建

在软件设计实现方面，Agent 模块作为中间调度层，承担了用户自然语言输入意图解析、任务拆解、多模型调用和任务上下文管理的核心职责。系统开发过程中，基于 LangChain 框架搭建多 Agent 协同环境，结合 Qwen-Max 大语言模型对用户指令进行语义理解，将自然语言请求转化为结构化任务命令。

Agent 通过内置的角色模板（Role Template）与功能权限（function\_list）管理机制，确保任务调度合理性与安全性。为了提升系统对复杂学习任务的响应能力，Agent 内置任务优先级分配与异步调度机制，避免多任务并发下阻塞或调度冲突问题，确保任务执行顺畅。

用户界面方面，系统初期采用命令行终端交互界面，用户通过自然语言输入指令，Agent 解析后返回结果。客户端与服务器之间采用异步通信机制，保障高并发请求下的实时响应，接口统一设计为 JSON 结构，便于前后端解耦开发。

系统在多任务调度、高并发环境、远程监督数据质量及深度模型推理延迟方面均遇到挑战。早期异步任务调度中，高并发请求导致的阻塞问题，通过引入协程池与事件循环优化解决，保障了任务实时响应。远程监督数据存在标签噪声严重、正负样本比例失衡问题，后续采用置信度阈值过滤与 Attention 句子重加权机制，有效提升关系抽取精度。此外，大语言模型调用延迟高问题，通过本地缓存 RAG 召回结果与图谱实体相似度预计算策略，显著降低了复杂查询响应时间。

---

系统部署方法上，Agent 与 MCP 服务端部署于本地 Linux 系统，Python 环境通过 conda 虚拟环境统一管理。

通过强化语言理解、任务拆解、多模型调度协同，配合 RAG 增强检索、GraphRAG 知识图谱结构化管理与机器人自主导航，形成了一个软硬件一体、多模态交互、个性化学习支持功能齐全的智能教育助手系统。

### 12.3.3 基于 GraphRAG 的知识图谱构建

#### 1. 数据预处理

数据预处理时，系统首先针对 PDF 文件类型开发了差异化文档解析策略。对原生 PDF，利用 PyMuPDF 库解析 PDF 对象树，直接提取段落文字及排版结构。对于扫描版 PDF，系统自动检测其是否存在可提取文字层，若检测失败则判定为扫描 PDF，调用 Tesseract OCR 进行文字识别。为了提升 OCR 识别后的文本结构化效果，结合了版面分析（Layout Analysis）技术，对识别结果的行块、段落、标题、表格结构进行还原，尽量保持原文档的逻辑层次与阅读顺序，避免直接线性化导致语义混乱的问题。

针对网页类文本数据，系统采用 requests 库进行网页爬取，配合 BeautifulSoup 完成 HTML 标签清洗与正文提取，去除无关广告、导航栏、评论区等非教学内容，同时保留教学内容中的图片路径、超链接文本、公式标签等结构信息，保障知识片段的完整性。Word 文档则利用 python-docx 库解析段落、标题、表格单元格及批注内容，将其统一转化为结构化文本格式。

#### 2. 命名实体识别 NER

命名实体识别旨在将非结构化文本中识别出实体和其类型，例如人名、组织、地点、医疗代码、时间表达、数量、货币价值、百分比等。

本项目采用 BERT 来进行识别命名实体，使用预训练的 BERT 模型作为基础，通过在特定领域的标注数据上进行微调来适应 NER 任务。输入文本经过 BERT 处理，输出每个词的特征表示。最后在 BERT 输出层之后，加上一个线性层用于实体的分类。






图 12 BERT 模型结构图

(1) 预训练与微调：项目使用的 BERT 模型已经在大规模通用语料库上进行了预训练，这为其提供了丰富的语言知识。通过在特定领域的标注数据上进行微调，模型能够更好地适应 NER 任务，并提高在该领域的性能。

(2) 特征表示的输出：输入文本在经过 BERT 模型处理后，每个词都会得到一个高维的特征表示。这些特征包含了词义、语法和语序等丰富的语言信息。

(3) 分类层的应用：在 BERT 模型的输出层之后，项目添加了一个线性层，用于将 BERT 生成的特征映射到不同的实体类别上，从而实现实体的分类。这一步骤是将深度学习模型的输出转换为 NER 任务所需结果的关键环节

### 3. 关系抽取 RE

关系抽取旨在从文本中抽取实体之间的语义关系。本项目采用 PCNN 模型配合远程监督学习方法。首先使用分段卷积神经网络（PCNN）来捕捉句子中的局部特征，并通过分段池化技术捕获结构信息。针对远程监督数据的噪声问题，引入 Attention 机制，评估同一 bag 中不同句子的重要性，提高关系抽取的准确性。实体间关系的标签通过远程监督自动获取，减少人工标注工作量。

## PCNN 架构图




图 13 PCNN 架构图

本项目采用的 PCNN 模型配合远程监督学习方法，通过分段卷积神经网络捕捉句子中的局部特征，并利用分段池化技术捕获结构信息，有效解决了远程监督数据噪声问题。Attention 机制的引入进一步提高了关系抽取的准确性，通过评估同一 bag 中不同句子的重要性，减少了人工标注工作量。此外，结合了多实例学习和自动特征学习的方法，避免了传统方法中需要进行复杂特征工程的问题。远程监督方法虽然能够自动构建大规模训练集，但存在的错误标注和长尾问题严重影响了性能。因此，本项目通过引入 Attention 机制和利用 PCNN 模型的优势，有效地提高了关系抽取的准确性和效率。

本项目的 PCNN 模型配合远程监督学习方法，通过引入 Attention 机制和利用 PCNN 模型的优势，有效地解决了远程监督数据的噪声问题，提高了关系抽取的准确性和效率。同时，通过结合直接监督数据，进一步提升了模型性能。

### 4. 属性抽取 AE

属性抽取的任务是从文本中提取实体的描述性属性。使用 `pretrain_language` 模型来提取属性，具体模型流程为：句子经过 BERT 编码，原句可以获得丰富的语义信息。得到的结果输入到双向 LSTM 中，输出结果可以得到句子的关系信息。

### 5. 知识图谱构建

---

构建知识图谱是将抽取的实体、关系和属性结构化存储，形成可查询的图数据库。使用图数据库 Neo4j 存储实体和关系，根据实体识别和关系抽取的结果，建立节点和边。接着为图谱中的每个实体和关系添加属性，如实体的描述性信息、关系的类型等。

## 12.4 实验机器人问答实现

### 12.4.1 GraphRAG 架构：知识检索增强生成

在本项目的个性化数字教育学习助手系统中，GraphRAG 作为上层应用，承担着知识检索与内容生成的重要职责。其设计核心是将结构化的领域知识图谱与大语言模型（LLM）生成能力相结合，通过 RAG（Retrieval-Augmented Generation）技术实现深度语义理解、精准知识检索以及高质量内容生成。工程实现过程中，GraphRAG 首先基于 Neo4j 图数据库搭建教育领域知识图谱，实体节点包括课程概念、公式、定理、题型、学科术语等，关系边则刻画概念依赖、包含、推导、应用等多元关系，保证知识组织的系统性与语义完备性。

知识图谱数据来源于前期经过数据清洗与标准化预处理的教材、题库、教学文档等多源异构数据。图谱构建过程中，系统采用命名实体识别、关系抽取、属性抽取模块，自动识别文本中的知识实体与关系，并将其转化为图数据库中的节点与关系结构，形成多跳、多维度的专业知识网络。实体属性字段中记录知识点定义、适用场景、典型例题、知识点层级等信息，增强知识图谱的可解释性和应用灵活性。

在内容生成阶段，GraphRAG 利用 LangChain 框架构建检索增强生成链路。用户输入问题首先经 ModelScope Agent 意图解析模块转化为结构化查询指令，GraphRAG 根据意图类型选择检索方式。对于知识型问答，优先通过向量召回机制在知识图谱对应的向量库（FAISS）中检索相似实体与关系片段，召回结果作为上下文补全文档，随后将用户问题与召回内容一同输入至大语言模型 Qwen-Max，生成自然语言答案。这种检索+生成的协同模式，有效提升了回答的上下文相关性、专业性与准确性。

在复杂推导型问题或学科逻辑问题生成过程中，GraphRAG 不仅依赖向量检索，还构建问题相关的子图，利用 VF2 子图匹配算法筛选知识图谱中与问题目标实体相关联的路径，提取其逻辑关系链，再将子图内容转化为上下文补充输入至语言模型，指导模型生成过程。这一机制显著增强了生成答案的推理链条完整性与知识逻辑可追溯性，解决了纯生成式 LLM 在专业领域知识空洞和逻辑不严谨的问题。

系统部署方面，GraphRAG 模块部署于本地 GPU 服务器环境，Neo4j 图数据库存储，模块间通过 MCP 协议异步通信，统一采用标准 JSON 消息结构，保障模块互操作性。整个 GraphRAG 模块实现了从结构化知识建模、语义检索、逻辑关系追踪到检索增强内容生成的一体化流程，为学习助手系统提供了高

---

效、灵活、可解释、可扩展的知识支撑与内容生成能力，极大提升了个性化学习服务的交互体验与实用价值。

### 12.4.2混合检索策略

在知识检索模块设计中，系统采用了混合检索策略，充分结合传统倒排索引、子图匹配检索以及基于向量嵌入的语义检索方法，以兼顾查询效率与语义理解能力。软件实现层面，检索模块基于 Python 语言开发，使用 Whoosh 库构建倒排索引系统，管理教育术语、题目关键词等文本型实体数据。对于简单概念查询，如“牛顿第二定律”、“微积分定义”等，用户输入的自然语言请求经 ModelScope Agent 解析后，将关键词抽取转化为倒排索引检索条件，实现毫秒级响应，保证基础检索任务的高效执行。

### 12.4.3意图解析联合模型

在复杂查询场景中，系统首先基于用户自然语言问题构建查询图（query graph）。该查询图由待检索的实体、目标关系、约束属性组成，构建过程依托 GraphRAG 模块，通过命名实体识别（NER）与关系抽取（RE）模型解析问题文本，提取核心实体与潜在关系。图匹配阶段，系统采用改进版 VF2 子图同构匹配算法。为解决传统 VF2 在大规模知识图谱检索时性能瓶颈问题，开发过程中加入实体最短路径预计算机制，采用 Floyd-Warshall 算法离线计算实体间最短路径矩阵，并通过节点相似度矩阵筛选候选子图，显著降低匹配计算复杂度，提高复杂查询响应速度。

语义检索部分，系统将 Neo4j 图数据库中的实体节点与关系边，通过 TransE 嵌入模型映射至共享向量空间。TransE 模型在训练阶段，将实体和关系编码为向量，优化使得  $h + r \approx t$  成立（ $h$  为头实体向量， $r$  为关系向量， $t$  为尾实体向量），实现实体对与关系的语义映射。为提升嵌入表示质量，系统在 TransE 基础上引入对比学习机制，通过最大化正样本对与最小化负样本对间的欧氏距离差值，增强向量空间中实体关系语义结构的区分能力。训练过程使用 PyTorch 框架，利用图谱实体对与关系三元组数据，构建正负样本对，迭代优化嵌入参数。

为应对知识图谱天然不完备问题，系统实现了基于知识推理的扩展检索机制。工程实现中，采用基于图神经网络（GNN）的推理方法，通过在实体邻居节点间消息传递，预测潜在但未显式存储的关系路径。具体选用 GAT（Graph Attention Network）模型，通过注意力机制自适应学习邻居节点对目标节点的重要性权重，动态聚合邻居特征，推断隐含实体关系。训练过程中，将已标注关系作为监督信号，优化注意力

---

权重参数与节点特征表示。模型采用 DGL 库搭建，数据训练阶段基于教育图谱实体关系子图，迭代更新节点表示与预测关系路径。

在开发过程中，检索模块面临复杂子图匹配耗时长、图神经网络推理延迟高的问题。为此，倒排索引部分通过分词优化与关键词权重倒排，降低匹配文档数量；VF2 算法部分引入实体最短路径与节点相似度双重预筛选，减少子图候选集规模；语义检索部分将 TransE 嵌入向量提前批量计算存储，检索阶段仅执行向量近邻搜索，提升召回效率。GNN 推理部分采用批量邻居采样（Neighbor Sampling）策略，减轻大图场景下内存与计算压力，同时将推理结果缓存，复用于多轮查询，避免重复计算。

系统部署方法方面，检索与推理模块部署在本地服务器，模块间通过 MCP 协议异步通信，统一 JSON 消息格式，保障多源检索调度的一致性与灵活性。最终构建完成的检索系统具备毫秒级简单查询响应、秒级复杂查询匹配与拓展关系推断能力，全面支撑个性化学习助手的知识服务需求。

#### 12.4.4 问答优化：错误标注修正与用户反馈闭环

建立用户反馈闭环机制，实时收集和分析用户与系统的交互日志，包括用户的输入、系统的回答以及用户的反馈等信息。通过数据挖掘和分析技术，识别出用户常见的问题类型、高频错误问题以及对系统回答的满意度等关键信息。根据这些分析结果，动态调整知识图谱的内容和结构，及时修正知识漏洞或错误信息，同时对 LLM 的输出进行优化调整，如对高频错误问题进行标注和针对性优化，使其能够生成更准确、更符合用户需求的回答。通过这种持续的反馈和优化过程，不断提高系统的性能和用户体验。

### 12.5 实验机器人的整体功能实现

#### 12.5.1 多模块协同架构实现

引入基于感知-规划-行动的 Agent 框架，作为系统的智能控制核心，实现对各模块的统一协调和管理。Agent 通过感知模块实时获取用户的输入和环境信息，基于预设的规则和策略进行规划和决策，然后通过行动模块输出相应的指令或回答。在 Agent 框架中，设计多 Agent 协同工作机制，针对不同的功能模块（如知识融合、实时性保障、用户反馈闭环等）配置专门的 Agent，并通过 MCP 协议实现 Agent 之间的高效通信和协作。同时，赋予 Agent 学习和自适应能力，使其能够根据用户的交互行为和系统的运行状态自动调整策略和行为模式，从而实现系统的智能化、自适应运行，为用户提供更加个性化、高效的服务。

#### 12.5.2 模态交互实现

在智能教育机器人助手的开发中，多模块集成是一项复杂且具有挑战性的任务。为了实现一个功能全面、用户体验良好的系统，项目团队需要将多个模块进行无缝集成，包括知识图谱、GraphRAG、大语言

---

模型（LLM）、模型上下文协议（MCP）和 Agent 框架等。这一过程不仅涉及技术层面的挑战，还包括系统设计和优化方面的难题。

首先，多模块集成需要解决数据融合的问题。不同模块之间可能存在数据格式、数据结构等方面的差异，如何有效地整合这些数据，确保信息的一致性和准确性，是一个关键的技术难题。项目团队采用了多种技术手段来解决这一问题。首先，通过统一的数据格式和结构，确保不同模块之间的数据能够顺畅流通。例如，使用 JSON L 格式进行前后端的数据交换，确保数据的一致性。其次，数据清洗与预处理是确保数据质量的重要环节。在数据融合前，进行数据清洗和预处理，去除无用信息、进行文本标准化和分词等操作，确保数据的质量和可用性。此外，建立动态更新机制，实时同步网络上的最新数据，保持知识图谱的时效性和准确性。通过定期更新知识图谱，确保系统能够提供最新的信息。最后，对 LLM 进行微调，以适应教育领域的特定需求。这包括去除无用信息、文本标准化、分词等步骤，确保模型能够有效识别和处理专业术语。通过微调，模型能够更好地理解和生成教育领域的相关内容。

其次，系统集成需要考虑实时性和稳定性，以确保多模态交互的准确性和流畅性。项目团队采取了多项措施来提升系统的实时性和稳定性。手势识别优化是其中的关键环节。通过优化手势识别算法，确保在不同光照和距离条件下都能准确识别用户的手势。特别是对于握拳和张手的判断，设计了根据距离大小动态调整的阈值，以提高识别的准确性。语音识别改进也是提升系统性能的重要方面。改进语音识别模块，采用深度学习模型和噪声抑制技术，提高在嘈杂环境下的识别准确率。通过多麦克风阵列和声源定位技术，进一步提升语音识别的效果。图像处理优化同样重要。优化图像处理流程，确保图像数据的实时传输和处理。使用 Socket 进行香橙派和移动机器人之间的双机通信，确保图像数据的快速传输和实时处理。此外，采用多线程和异步处理机制，确保系统能够快速响应用户的输入。通过异步处理，减少系统延迟，提升用户体验。

最后，系统集成还需要进行全面的测试和优化。在多模块集成的过程中，系统可能会出现模块间的协同问题，如数据同步、任务调度等。项目团队进行了全面的系统测试，确保各模块之间的协同工作。通过模拟实际使用场景，测试各模块之间的协同工作，确保数据同步、任务调度等功能的正常运行。针对测试中发现的问题，进行针对性的优化，提升系统的稳定性和性能。通过测试和优化，将 GraphRAG、LLM、MCP 和 Agent 框架进行深度集成，进行全面的系统测试，确保各模块之间的协同工作，通过测试和优化，

---

提升系统的稳定性和性能，并依据用户反馈，不断改进系统的交互体验，确保用户在使用过程中能够获得流畅的交互体验。通过这些措施，实现一个功能全面、用户体验良好的智能教育机器人助手。

### 12.5.3 典型应用场景

"慧伴同行"项目以其创新技术架构和丰富功能设计，在教育及相关领域展现出广泛应用前景和商业价值。系统的多场景适应性和可扩展性使其能够满足不同用户群体的多样化需求，从基础教育到专业培训，从学校教育到家庭学习，都有着巨大的市场潜力。



图 20 产品应用场景图

传统学校教育："慧伴同行"可以作为教师的智能助手和学生的个性化学习伙伴。在课堂环境中，机器人能够协助教师进行课堂管理，如点名签到、资料分发和课堂记录；在教学过程中，它可以演示复杂概念的三维模型，提供实时翻译服务，或为有特殊需求的学生提供个性化指导。

特殊人群教育：系统对特殊教育的价值尤为突出。对于有学习障碍或身体残疾的学生，机器人的多模态交互和移动服务能力可以打破传统教育中的障碍。例如，为视障学生提供语音导学，为听障学生提供文



---

字转换，为行动不便的学生提供移动服务支持。这种包容性设计使优质教育资源能够惠及更广泛的学生群体。

家庭教育：家庭是“智伴学行”的另一重要应用场景。作为家庭学习助手，机器人能够提供作业辅导、兴趣培养和习惯养成等多样化服务。与平板电脑等被动设备不同，移动机器人可以主动与儿童互动，通过游戏化学习提高参与度，同时避免过度屏幕时间带来的健康问题。

展馆和博物馆：博物馆等公共教育场所也是理想的应用场景。机器人可以作为智能导览员，根据参观者的年龄和兴趣提供个性化讲解；可以引导参观路线，避免拥挤；还可以通过问答互动深化学习效果。

企业培训：新员工培训中，机器人可以担任入职引导员，介绍公司制度、部门职能和业务流程；技能培训中，它可以模拟客户，提供反复练习的机会；安全培训中，它能够演示正确操作步骤。

老年护理和辅助：智能移动机器人学习助手可以陪伴老人，提供日常生活辅助，同时解答他们的疑问，提供情感支持。这一点可以从智能虚拟助手在教育领域的应用研究中得到启示，其中提到了智能虚拟助手具有的自然的人机交互、便捷的知识获取和完善的技术生态三个特征及其对教育产生的价值。

**12.6智能移动机器人学习助手在多个领域都有广泛的应用前景，其跨领域知识图谱和生成式对话的能力，以及与移动机器人技术的结合，使其成为了一个具有广泛应用潜力的技术解决方案。**

---